

گزارش نهایی پروژه: تبدیل نسخه استودیویی به نسخه لایو با کمک هوش مصنوعی

آهنگ «بزن باران» از ایهام | ابزار اصلی: Claude Code به همراه مدل های جداسازی صدا و Kits.ai

۱. هدف و ایده

هدف، تبدیل یک آهنگ استودیویی به اجرای زنده کنسرتی بود. برخلاف ابزارهایی مثل Suno که آهنگ را از نو می سازند، در این پروژه صدای اصلی خواننده ها و گروه حفظ شد و «فضای کنسرت» (شمارش درامر، تشویق، همخوانی مردم و صدای سالن) دور آن ساخته شد. کل کار با گفتگو و بازخورد شنیداری دانشجو هدایت شد: ۵۱ پرامپت و ۲۹ نسخه.

۲. تحلیل اولیه

- نمونه استاد: وکال اصلی حفظ و موزیک بازسازی شده بود. بیس زیر ۶۰ هرتز از ۲۵٪ به ۱۱٪ انرژی و میانه ها (۲۵۰ تا ۱۰۰۰ هرتز) از ۲۱٪ به ۳۵٪ رسیده بود و استریو پهن تر شده بود. شمارش درامر، جیغ و همخوانی مردم هم داشت.
- آهنگ دانشجو: تمپو ۱۰۰، دو خواننده (خواننده ۲ در گرس ها، یک اکتاو بالاتر)، و زمان بندی دقیق بخش ها از روی رنگ صدا (MFCC) و نت.
- نسخه لایو واقعی همین آهنگ: ۲ نیم پرده بالاتر و ۳٪ تندتر اجرا شده است. از آن صدای واقعی تشویق و همخوانی مردم برداشته شد.

۳. ابزارها

Python (librosa, numpy, scipy, pedalboard, ffmpeg)؛ مدل های هوش مصنوعی جداسازی صدا UVR-MDX- NET-Voc_FT (وکال و موزیک) و UVR_MDXNET_KARA_2 (خواننده اصلی و صداهای پشت)؛ Kits.ai برای تبدیل صدای خواننده به صدای زنانه؛ و Claude Code برای تحلیل، ساخت، بررسی خودکار کیفیت و گزارش نویسی.

۴. مسیر کار: روش های امتحان شده برای همخوانی جمعیت

روش	نتیجه	درس
کپی صدای خواننده با تغییر کوک و تأخیر (نسخه ۱ تا ۷)	حس «حمام»، اکو و صدای رباتی	کپی کمی دیرتر صدای خواننده را گوش اکوی خود او می شنود
جمعیت بی کلام هم ریتم با خواننده (نسخه ۸ و ۹)	تمیز، ولی همخوانی شنیده نمی شد	بدون کلمه، حس همخوانی منتقل نمی شود
صداهای Kits.ai با زمان بندی جمله به جمله (نسخه ۱۰ و ۱۱)	طبیعی تر؛ برخی جمله ها رباتی	هر صدا یک «آدم» متفاوت است؛ کیفیت تبدیل در جمله ها فرق دارد
همخوانی واقعی از نسخه لایو (نسخه ۱۲ تا ۱۶)	واقعی ترین؛ در بند اول ناهم زمان	یک خواننده ی پشت صحنه وسط استریو بود؛ با برداشتن فقط کناره ها حذف شد
ضبط صدای خود دانشجو + تنظیم کوک خودکار (نسخه ۱۷)	کوک شد (اختلاف میانه ۰.۳ نیم پرده)	هم زمانی بدون پخش آهنگ هنگام ضبط سخت است

۵. نسخه نهایی (نسخه ۲۹)

- اینترتو: تشویق واقعی، شمارش درامر روی ضرب، هی هی های ریتمیک نرم و اوج ناگهانی برای ورود خواننده ۱ که با شروع آواز ۹ دسی بل کم می شود.
- بند اول و دوم: جواب واقعی مردم «بزن باران بزن» در مکث خواننده؛ صدای خود دانشجو (کوک شده) زیر پیش گرس؛ همخوانی واقعی لایو در بند دوم، هم ترازشده با DTW روی صدای خواننده ها (خطای کمتر از ۰.۱ ثانیه).
- گرس ها: خواننده ۲ خشک و غالب؛ زنان Kits.ai دور و نرم، مثل تماشاچی؛ همخوانی واقعی «فقط مردم» لایو (۱:۵۰ تا ۱:۵۳) در همه ی جاهای هم ملودی (۱:۲۰، ۱:۳۹، ۳:۱۵، ۳:۵۳) با پایان کشیده و فید.
- پایان: در ۳:۵۳ خواننده ها ساکت می شوند و فقط مردم «هوا هوای خاطرات اوست» را می خوانند؛ بعد جیغ و تشویق. طول آهنگ برابر اصلی (۴:۱۳).
- میکس کنسرتی: بیس کمتر، میانه بیشتر، استریو پهن تر، ریورب سالن روی گروه، کمپرسور و لیمیتر (پیک -1 dB)؛ سقف بلندی جمعیت ۱.۵ دسی بل زیر خواننده.

۶. کنترل کیفیت و نقش دانشجو

هوش مصنوعی صدا را نمی‌شنود. برای همین دو مسیر کنترل استفاده شد. (۱) بررسی خودکار (build/qa.py): کلیپ، تیک، شروع یا قطع ناگهانی، صدای تیز و سازگاری تک‌کاناله. هر مورد مشکوک با مقایسه با نسخه‌ی بدون جمعیت، دستی تأیید یا رد شد. (۲) گوش دانشجو: ایرادهایی مثل «حمومی بودن»، «رباتی بودن»، «ناهم‌زمانی در ۰:۲۹» و «قطع ناگهانی در ۱:۲۳» را دانشجو پیدا کرد. برای هر کدام علت فنی پیدا و اصلاح شد (مثلاً ریورب دوباره، نرم‌کننده‌ای که شروع صدا را حذف می‌کرد، یا جواب مردم که با خط اول اشتباه هم‌تراز شده بود).

۷. جمع‌بندی و محدودیت‌ها

نتیجه‌ی اصلی: بهترین همخوانی جمعیت از صدای واقعی آدم‌ها به دست می‌آید (نسخه لایو واقعی، صدای خود دانشجو، Kits.ai). شبیه‌سازی با کپی صدای خواننده، هر قدر هم تنظیم شود، اکو و صدای ربّاتی می‌دهد. محدودیت‌ها: Suno به‌خاطر تکرار زیاد شعر را نپذیرفت؛ دالود مدل‌های تبدیل صدا در محیط کار مسدود بود؛ و تبدیل Kits.ai در برخی جمله‌ها ربّاتی بود و حذف شد. همه‌ی کدها، ۲۹ نسخه، پرامپت‌ها و گزارش کامل در مخزن گیت‌هاب ثبت شده است (REPORT.md، پوشه‌های build و output).